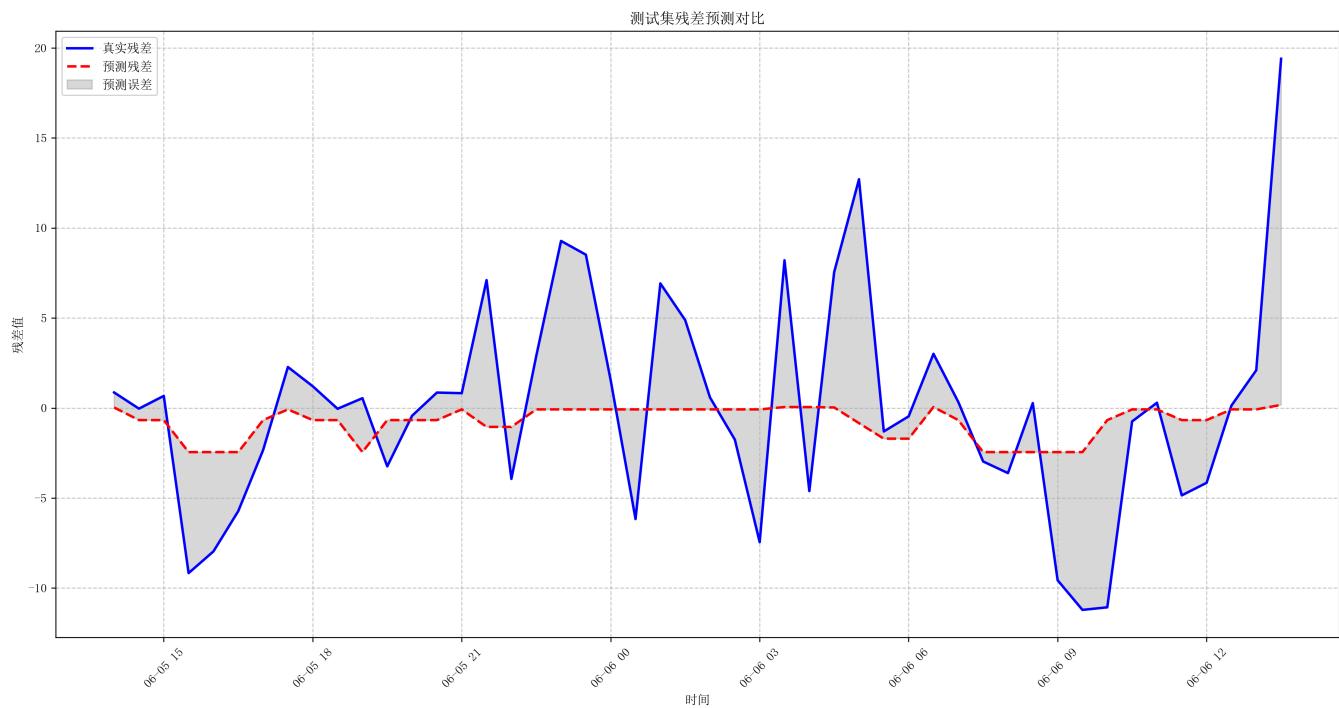
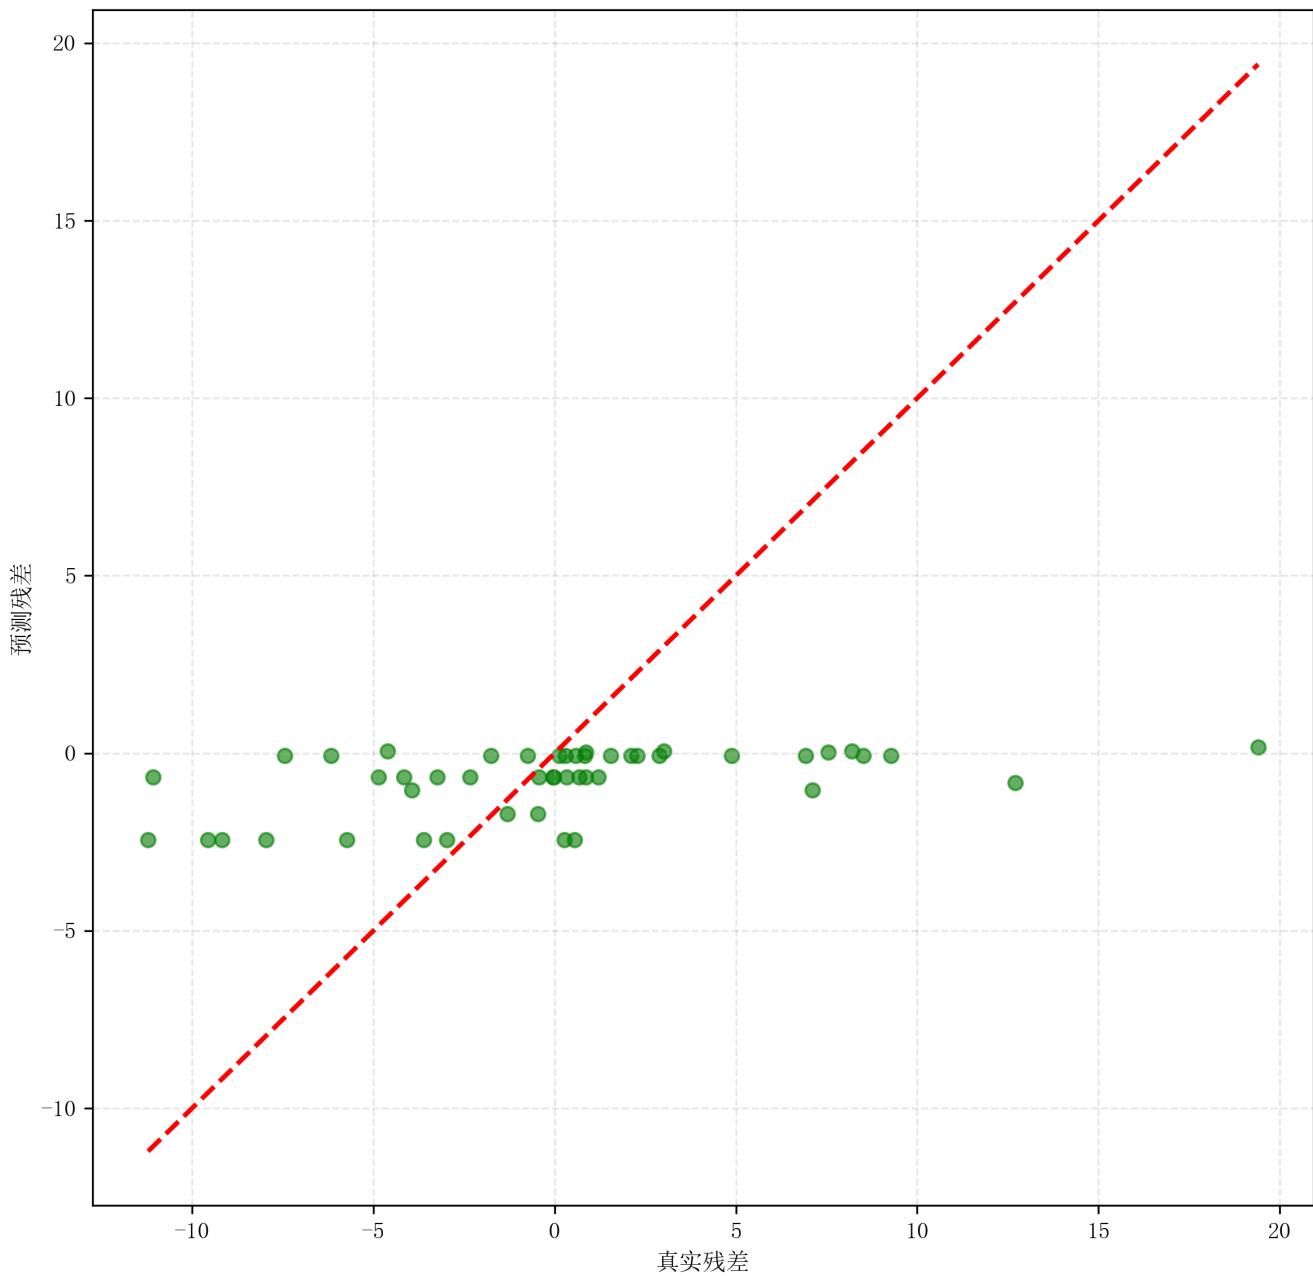


2025-06-14~15

- LGB + TabNet
- 修改LGB为残差修正



残差预测效果散点图



残差修正模型最终评估报告：

训练集: RMSE=9.9753, MAE=5.5141, R²=0.0577

验证集: RMSE=8.5967, MAE=5.9605, R²=0.0280

测试集: RMSE=5.6365, MAE=4.0605, R²=0.1092

这表明模型对残差的解释能力非常弱 (R²接近0表示模型几乎无法解释残差的变化)

可能的原因包括：

- 残差中可能没有明显的模式（即残差是随机的），因此任何模型都难以预测。
- 特征不足：我们只使用了SARIMA的预测值作为特征，可能不足以捕捉残差的模式。可以考虑加入更多特征（例如历史残差、时间特征、外部特征等）。
- 模型复杂度：可能需要调整模型结构（更复杂的模型或不同的模型类型）。

- 数据量：可能训练数据不足。

当前的残差修正模型效果确实不理想，但这不是最终结论。建议您：

1. 先进行残差诊断，了解残差的特性
2. 增加更多相关特征（特别是时间特征和滞后特征）
3. 尝试不同的模型架构
4. 进行更深入的超参数优化
5. 如果残差确实是随机的（没有可预测的模式），可能需要接受SARIMA模型已经是最佳选择

残差分析

残差的描述性统计分析

count	mean	std	min	...	75%	max	skewness	kurtosis	
residual	1744.0	-0.037854	9.901296	-72.344432	...	3.048907	124.435	1.066267	24.912577

- **均值(-0.038)**：非常接近0，表明SARIMA模型的预测**整体无偏**，没有系统性高估或低估。
- **标准差(9.90)**：较大，说明残差的**波动幅度较大**，预测存在显著误差。
- **极值范围(-72.34~124.44)**：存在极端异常值，表明某些时点的预测与实际值差距很大。
- **偏度(1.066)**：大于0，表示残差分布**右偏**，大部分残差集中在左侧（负值区域），右侧有长尾（大正值）。
- **峰度(24.91)**：远大于3，表明分布呈**尖峰厚尾**特性，存在比正态分布更多的极端值。

正态性检验：

Shapiro-Wilk 检验 (n=1744) p值: 0.000000 (**非正态分布**)

Jarque-Bera 检验 p值: 0.000000 (**非正态分布**)

含义：残差**不服从正态分布**：

1. 传统统计检验（如t检验）可能不适用
2. 极端值对模型性能影响更大
3. 可能需要使用鲁棒性更强的模型（如分位数回归）

平稳性检验：

ADF 统计量: -10.8327

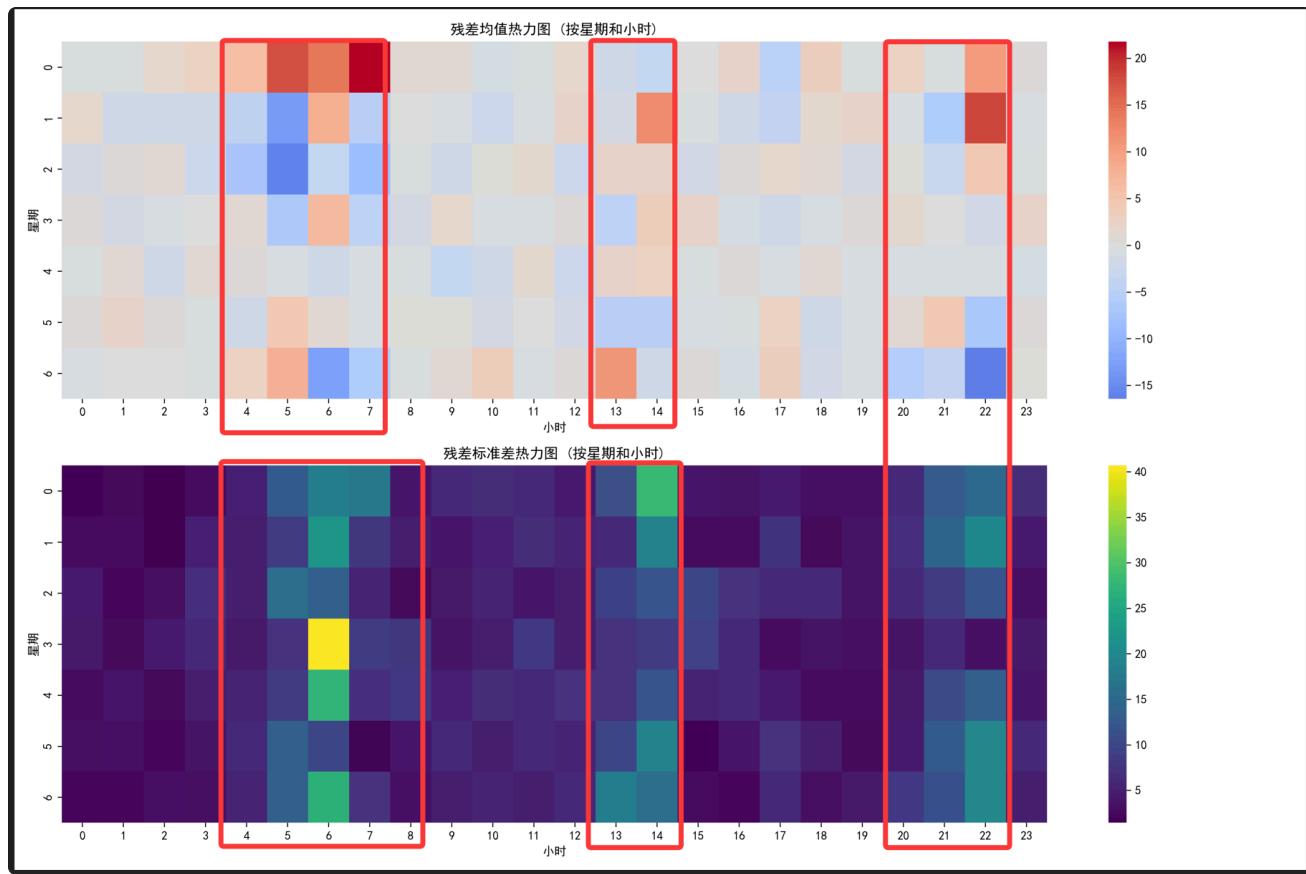
p值: 0.000000 (平稳)

KPSS 统计量: 0.0141

p值: 0.100000 (平稳)

- **结论：**残差序列是**平稳的**：

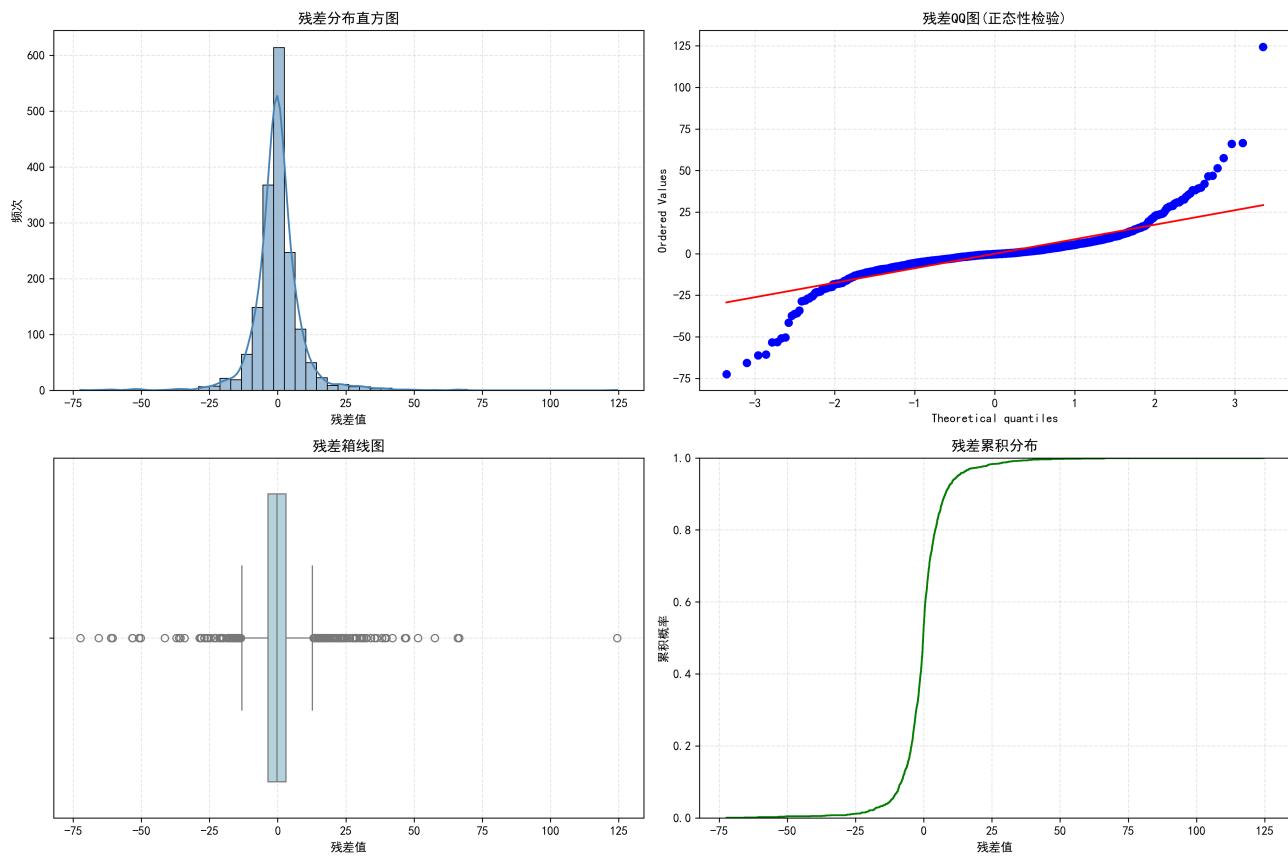
- 残差中没有明显的时间趋势或季节性
- 可以使用机器学习模型进行修正
- 残差中的模式是可学习的



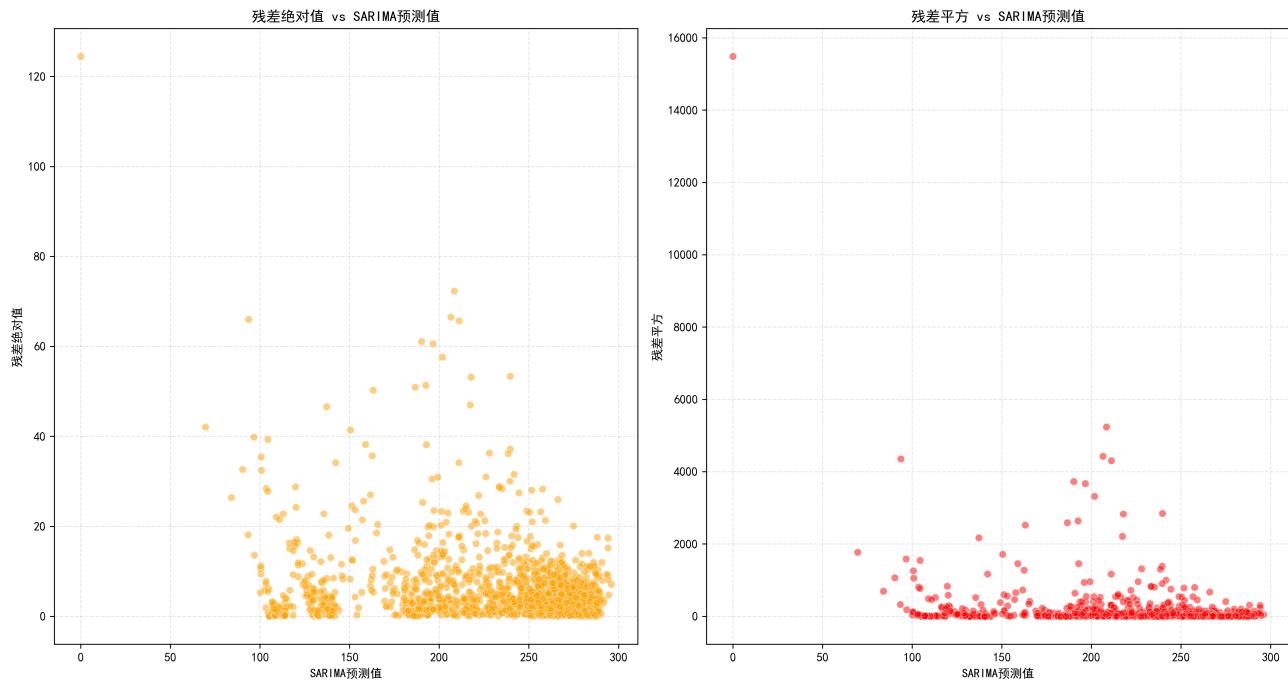
按时段来划分：

- 4~7
- 13~14
- 20~22

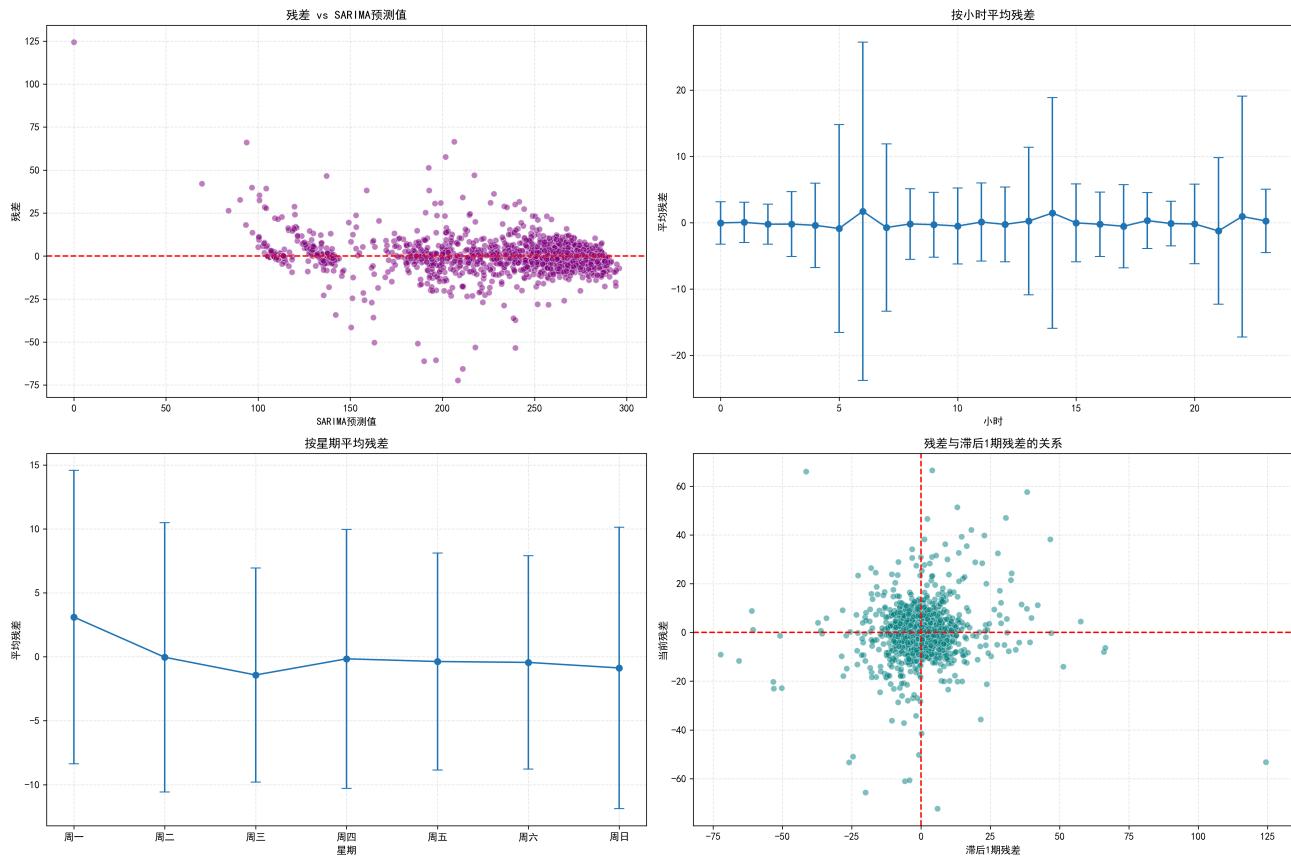
以上3个时段残差较大，应该是对应了三班倒的现实情况



残差值的分布大致在【-25, 25】，也存在大量的离群点



残差的平方相对和SARIMIA关系更明显



看“按小时平均残差”图，可以发现在5~7, 13~14, 21~22的残差均值是比较大的。
“按星期平均残差”图，周一，周二残差更大一些

综合分析：

1. SARIMA模型表现：

- 整体无偏但精度不足（标准差大）
- 在特定情况下出现显著预测偏差（极端值存在）

2. 残差修正潜力：

- 残差平稳 → 可建立有效的修正模型
- 非正态分布 → 需选择适当的模型和损失函数

3. 模型选择建议：

- 优先尝试分位数回归（预测残差分布）
- 使用Huber损失或分位数损失的LightGBM
- 添加滞后特征(lag1、lag24等)

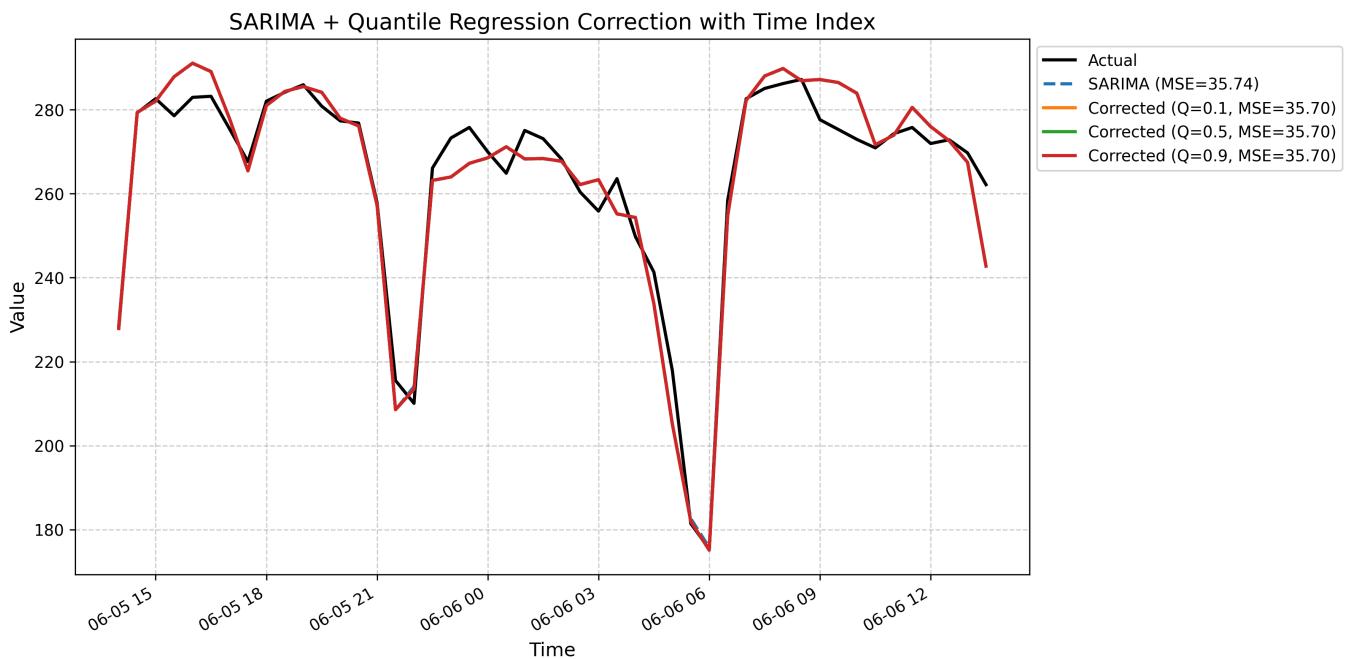
分位数回归

SARIMA MSE: 35.7364

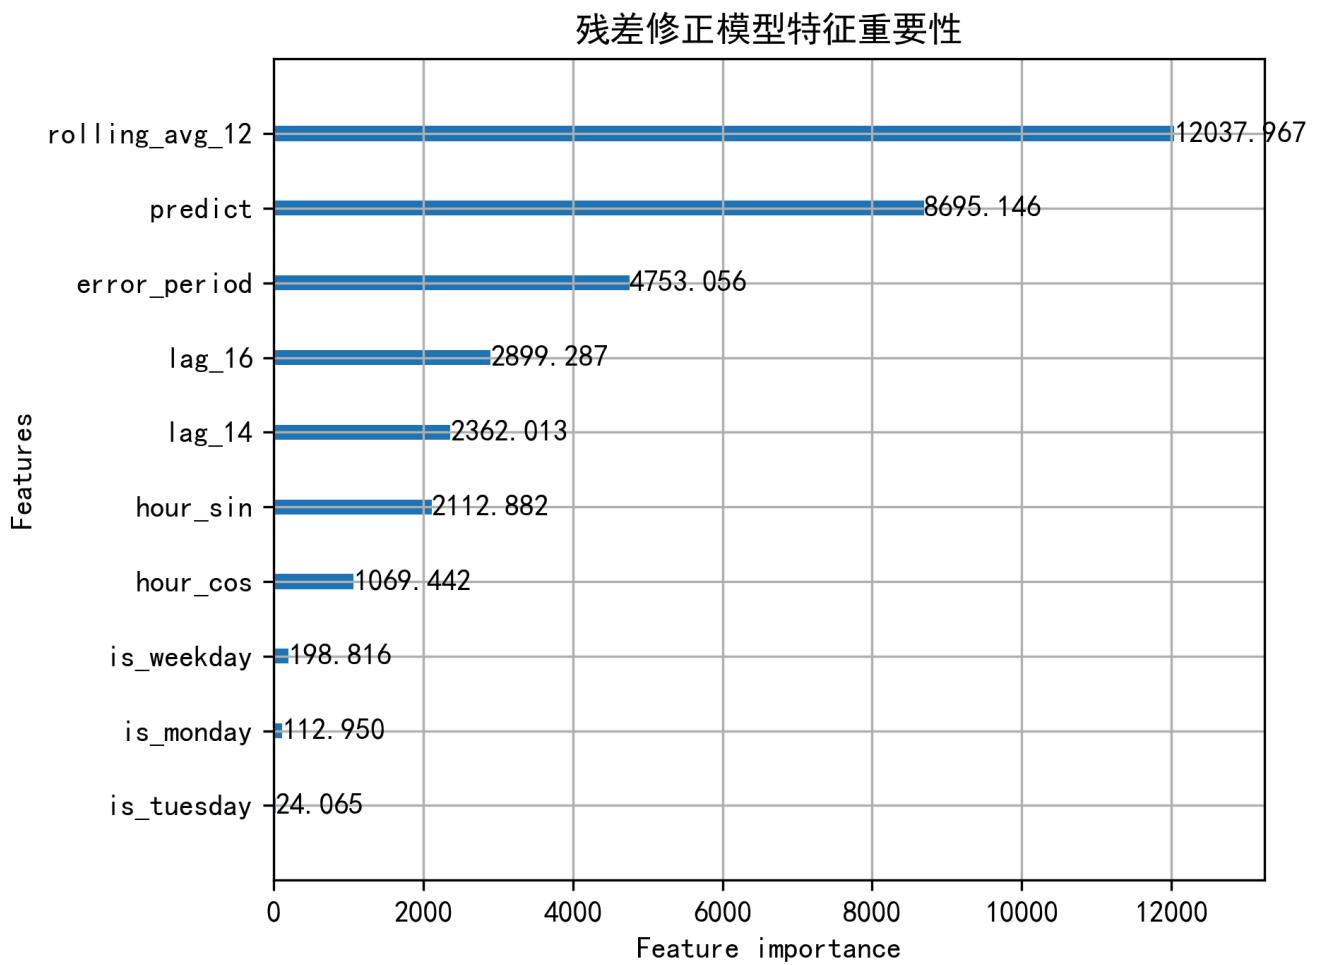
Corrected (Q=0.1) MSE: 35.6996

Corrected (Q=0.5) MSE: 35.6996

Corrected (Q=0.9) MSE: 35.6996



残差修正

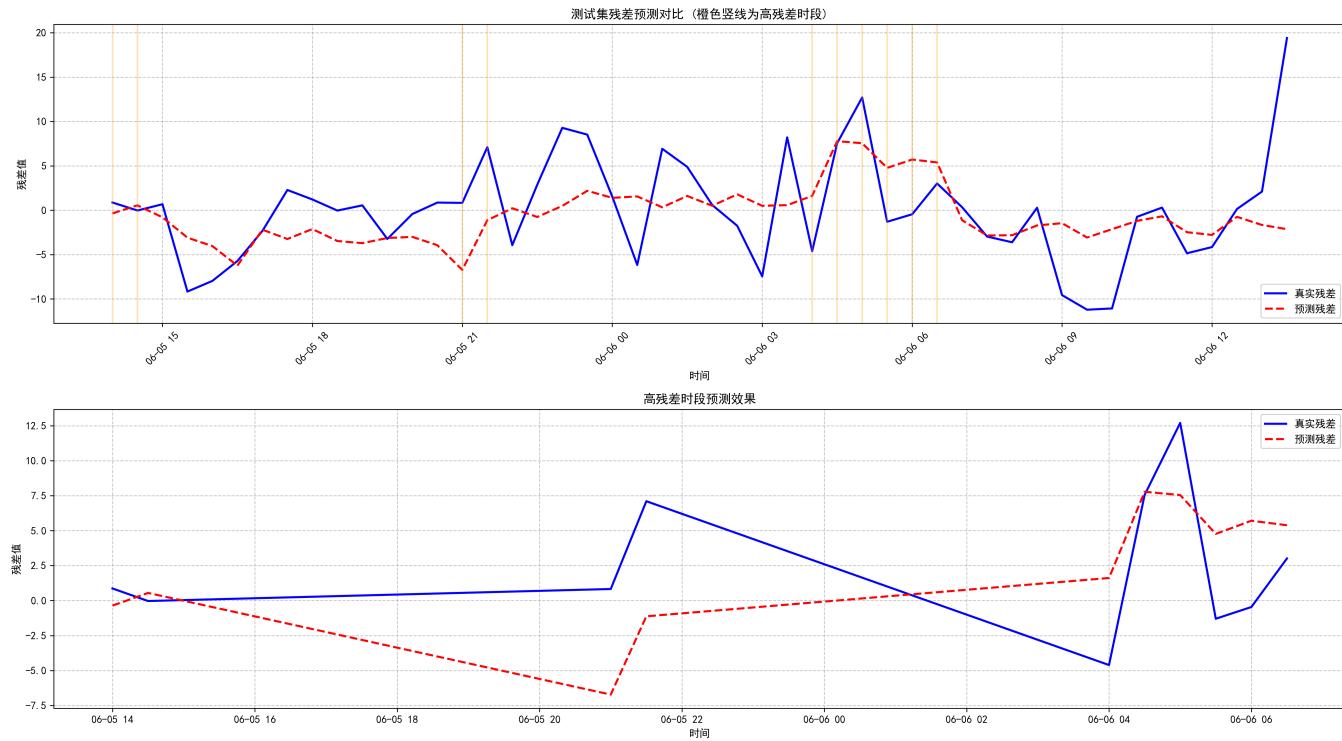


最优参数: {'learning_rate': 0.1, 'max_depth': 5, 'min_child_samples': 20, 'n_estimators': 500, 'num_leaves': 31, 'reg_alpha': 0, 'reg_lambda': 0, 'subsample': 0.8}

训练集: MSE=58.9250, RMSE=7.6763, MAE=4.0292, R²=0.3566

验证集: MSE=57.2824, RMSE=7.5685, MAE=5.3584, R²=0.2466

测试集: MSE=31.8762, RMSE=5.6459, MAE=4.1821, R²=0.1063



原始SARIMA预测 MSE: 35.6670

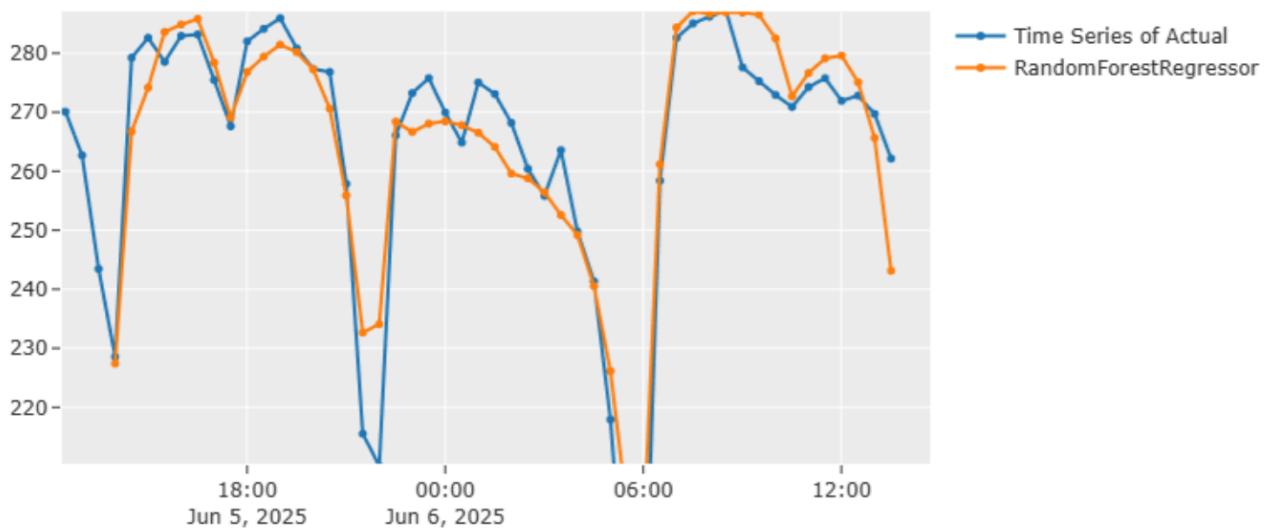
组合预测 MSE: 31.8762

提升比例: 10.63%

Random Forest w/ Cond. Deseasonalize & Detrending

这个是直接去做预测

Actual vs. Forecast (Out-of-Sample)



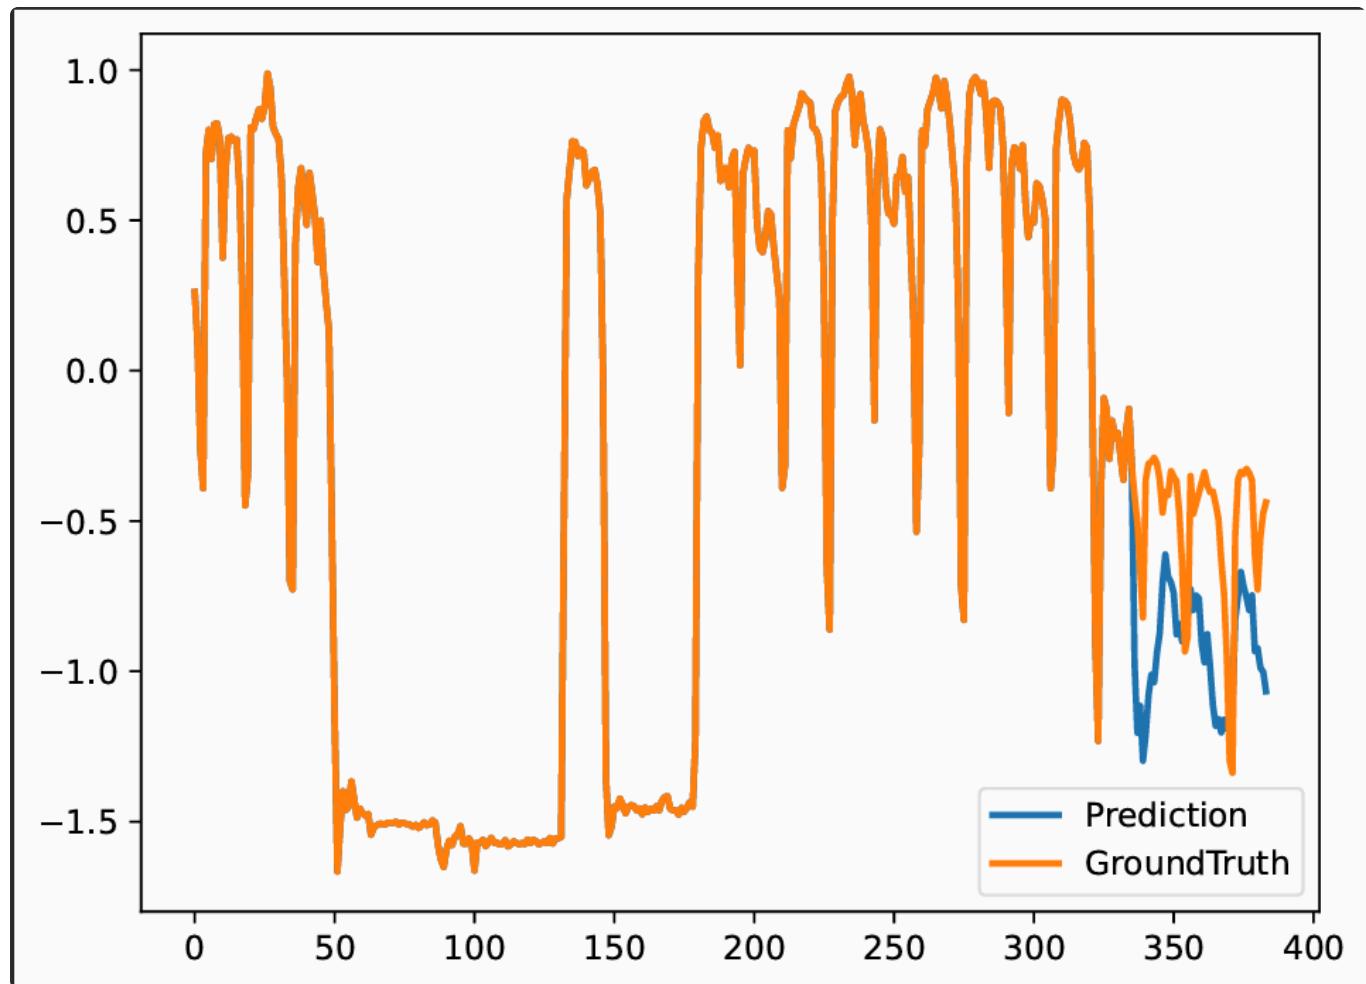
采用下面的做修正

RMSSE MAE RMSE MAPE SMAPE R2 MSE

auto_arima 0.1749 6.4919 8.8583 0.027 0.0271 0.8955 80.9714

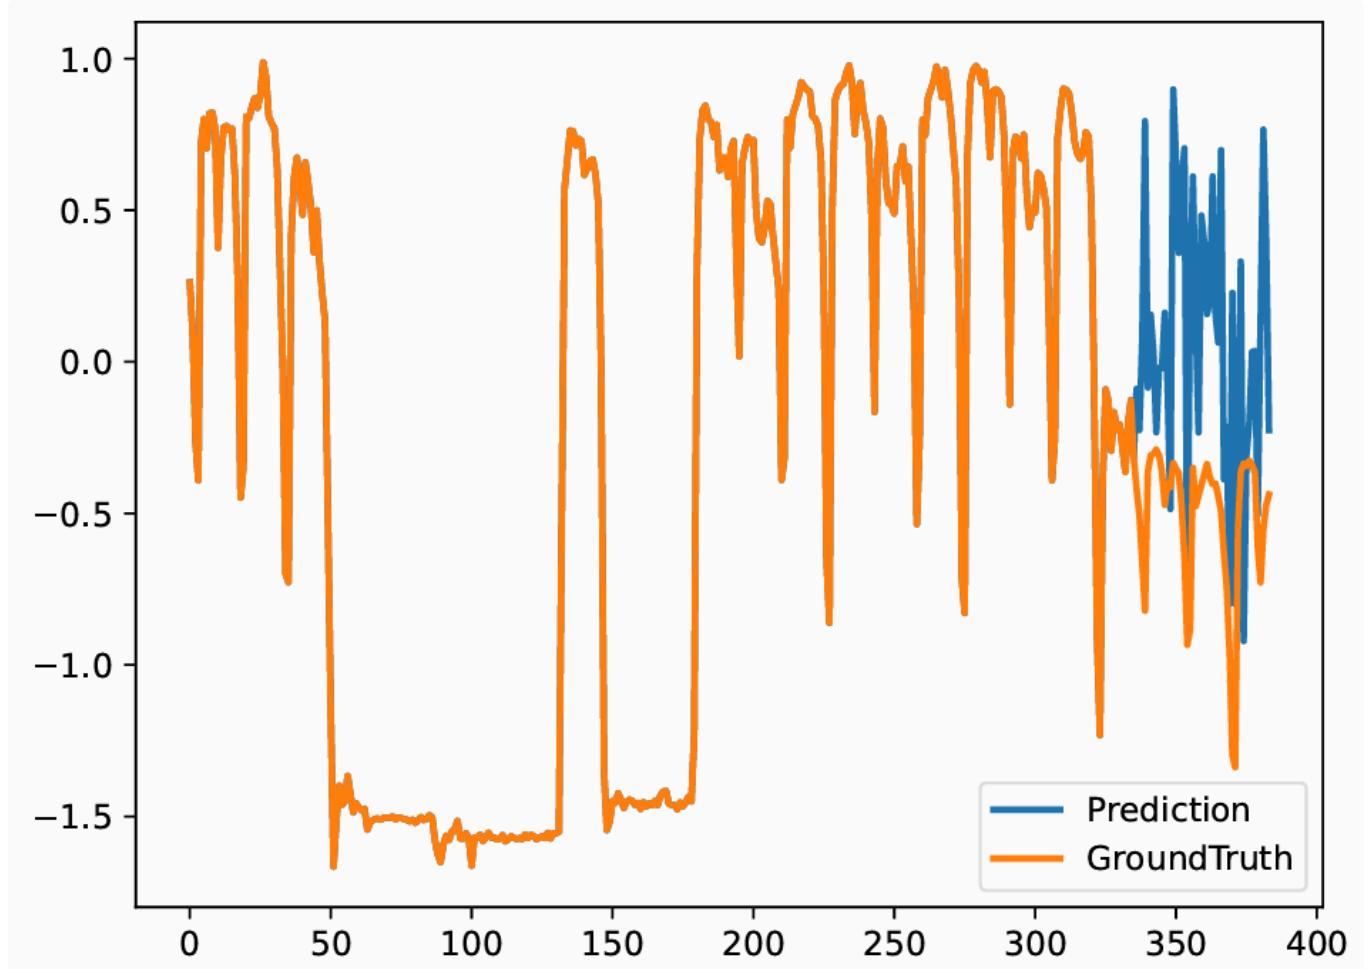
深度学习模型

Autoformer



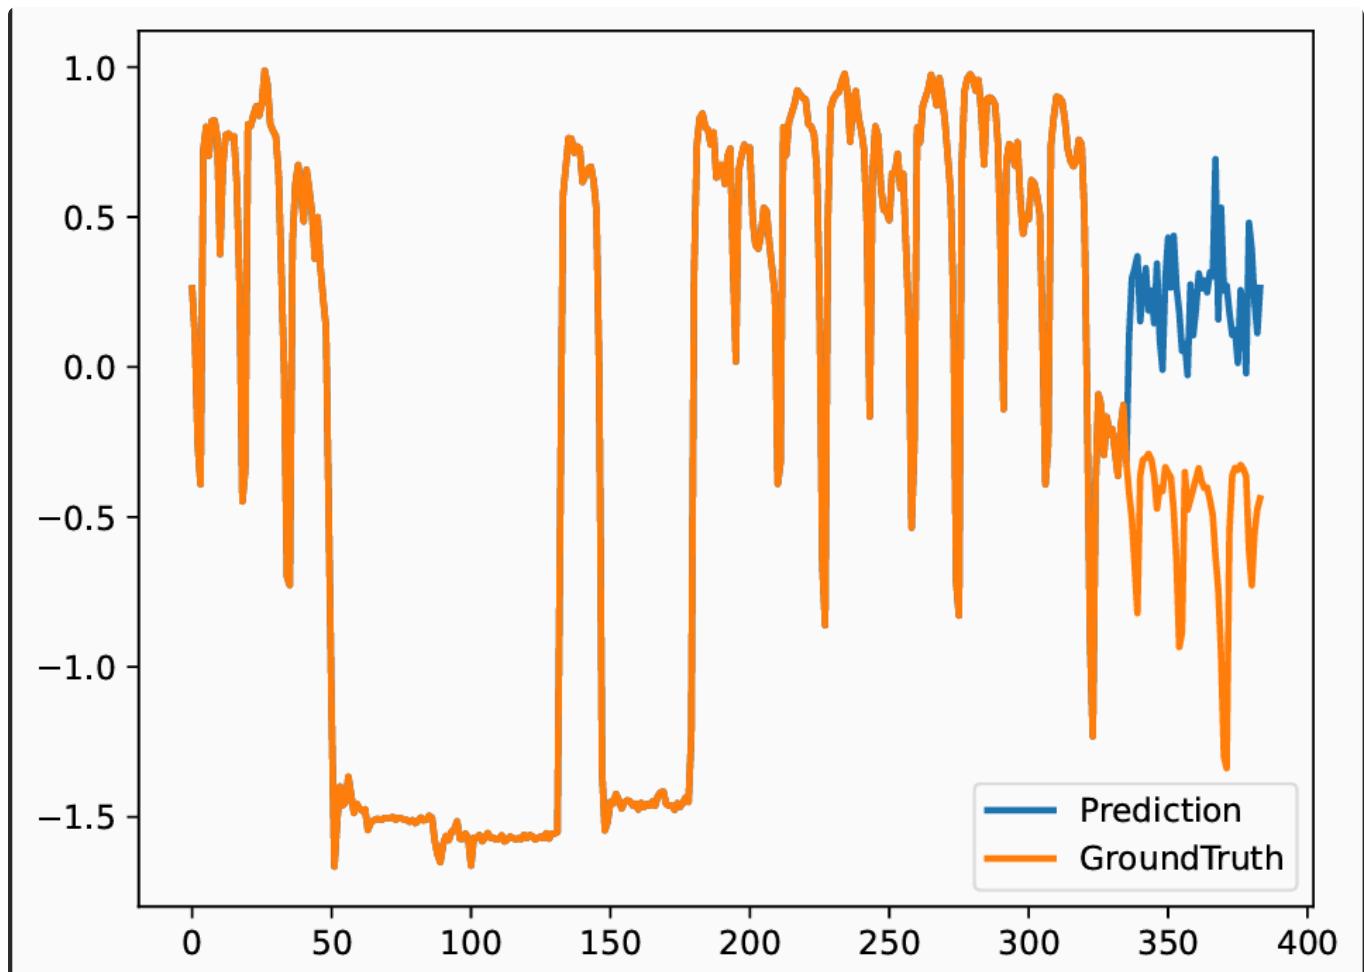
mse:0.580916166305542

TimesNet



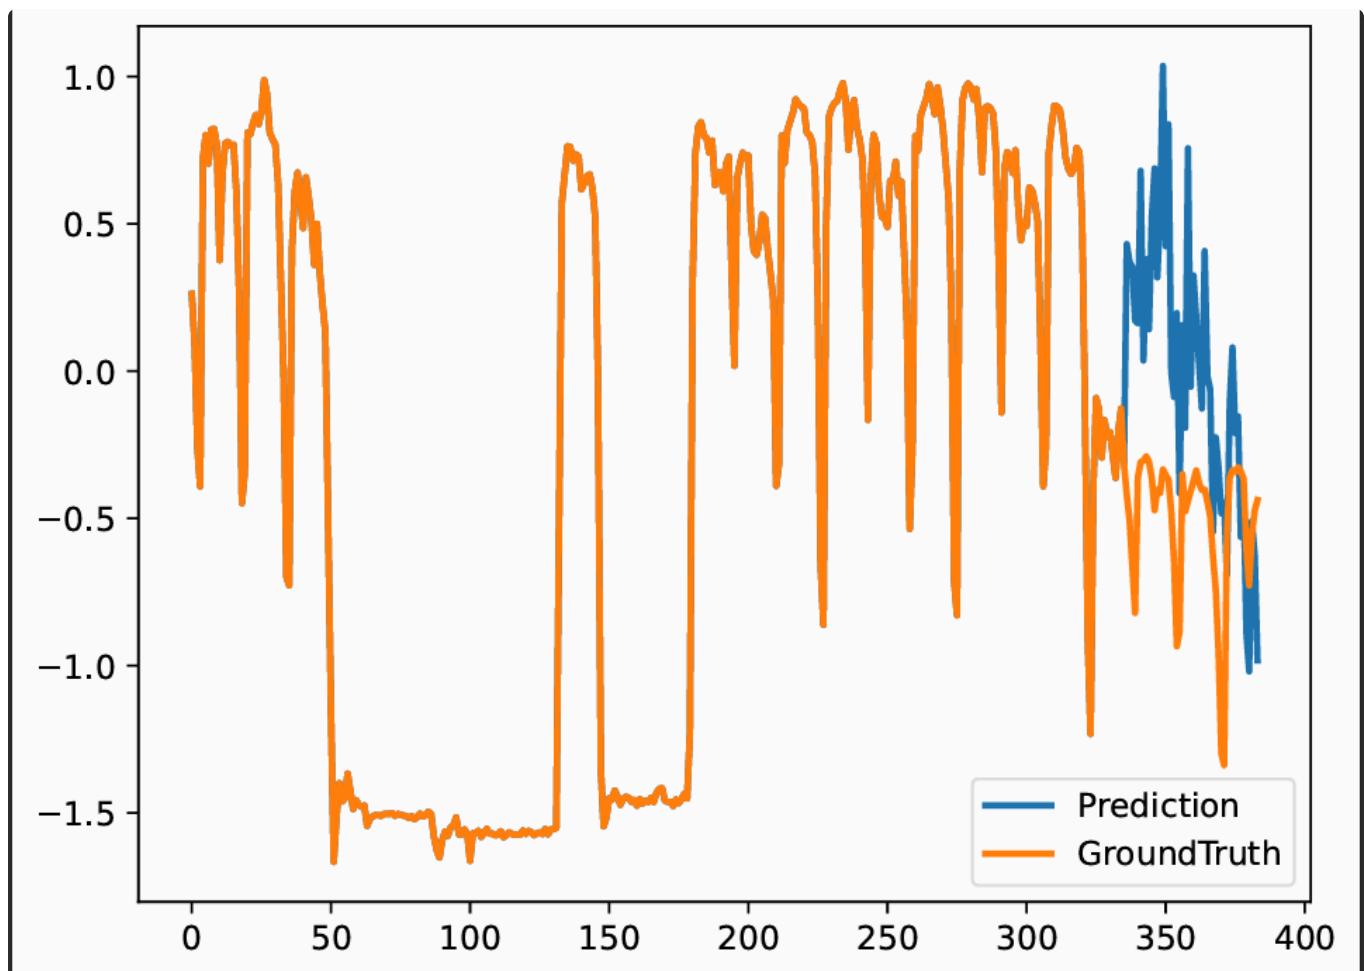
mse:0.6287055015563965, mae:0.6519007682800293, dtw:Not calculated

Crossformer



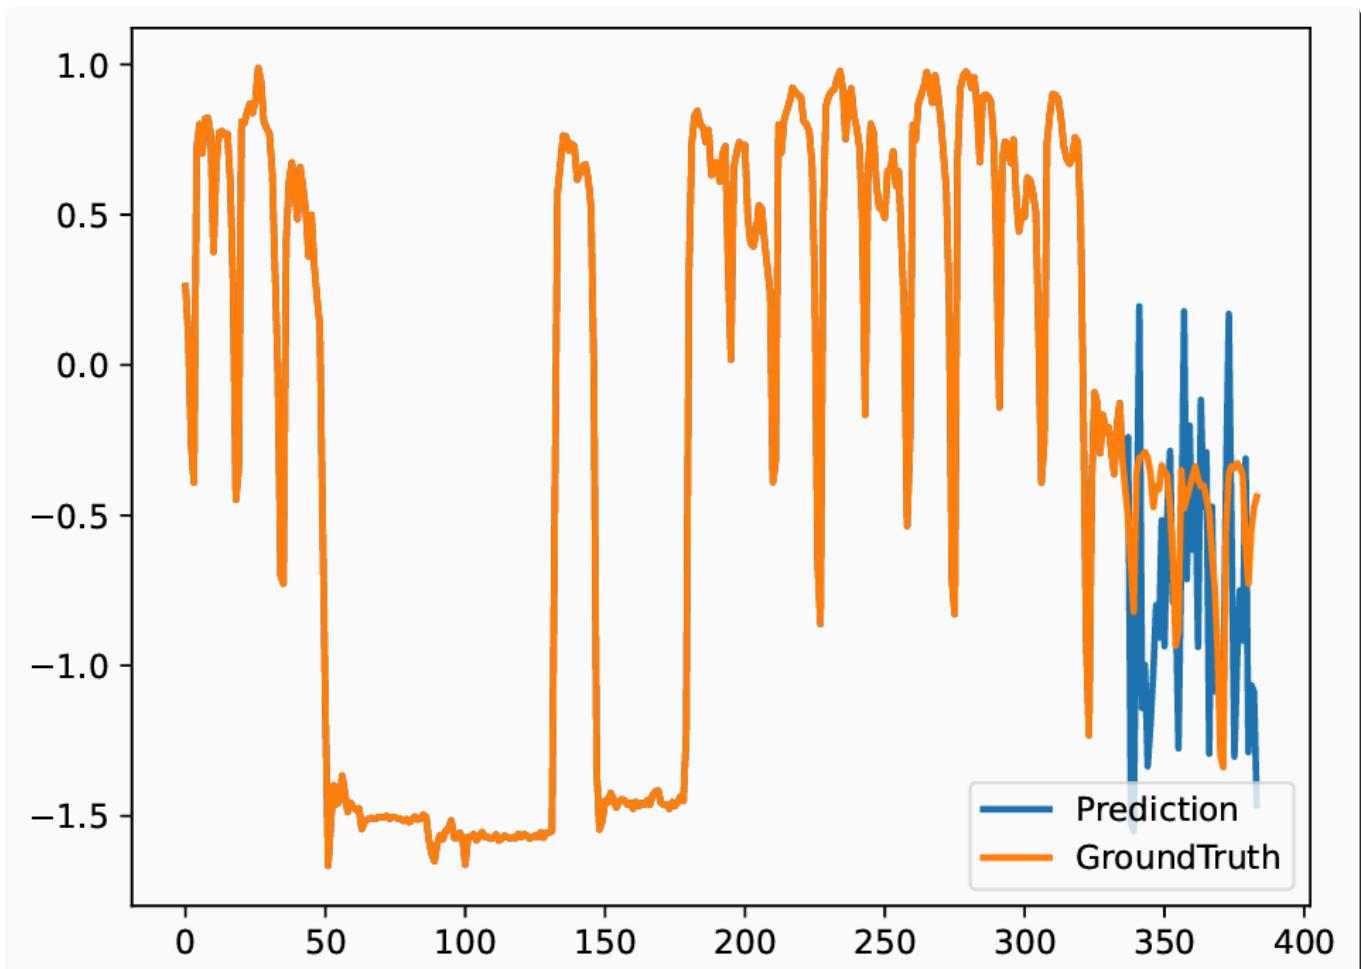
mse:0.7653908729553223, mae:0.7180525660514832, dtw:Not calculated

iTransformer



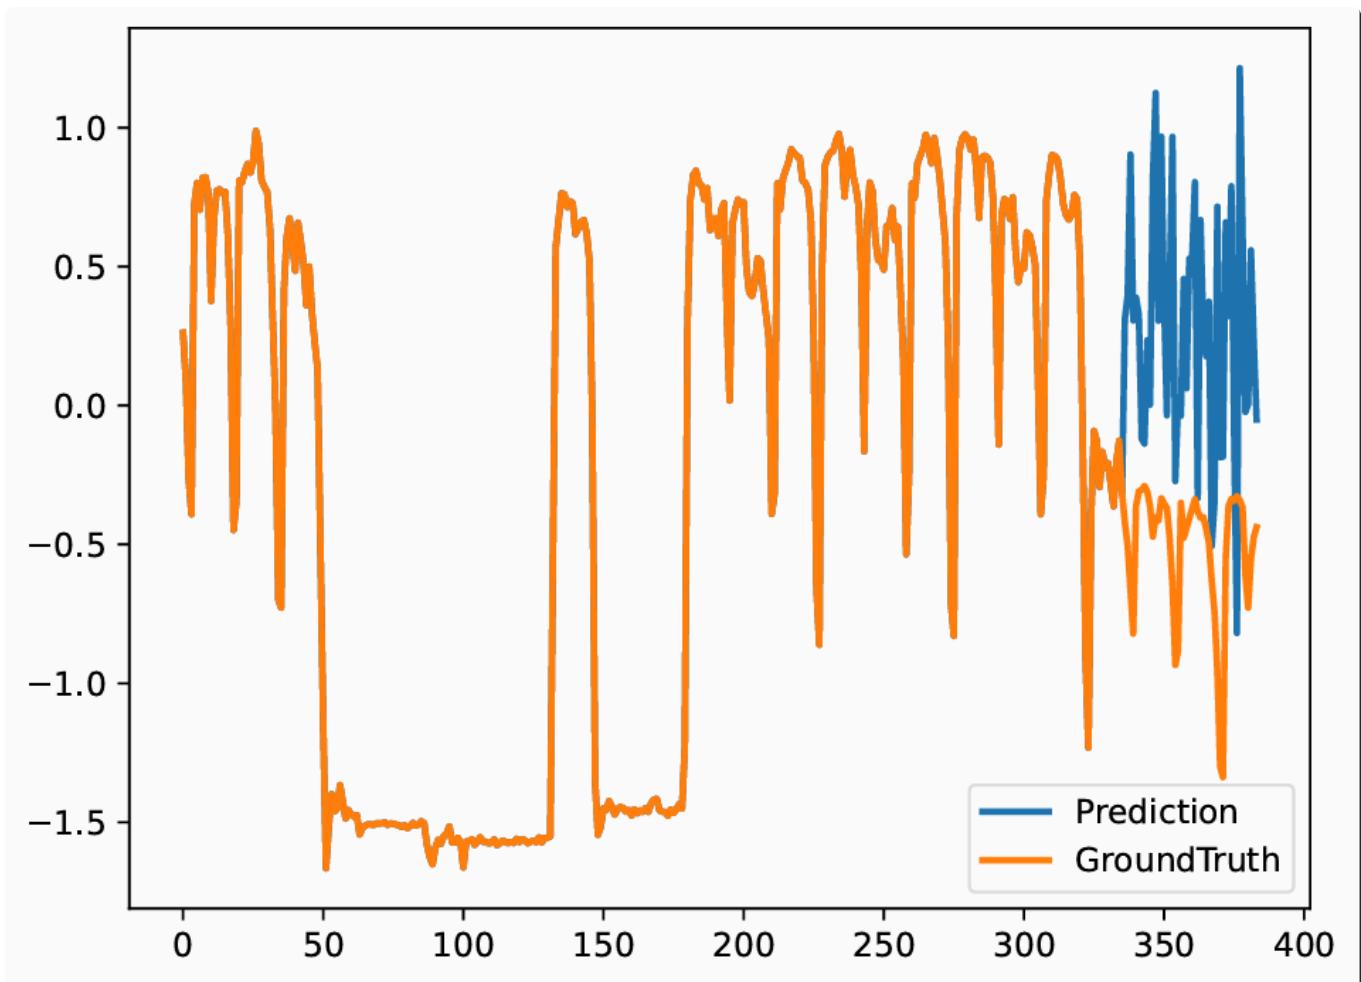
mse:0.39993593096733093, mae:0.5130232572555542, dtw:Not calculated

PatchTST



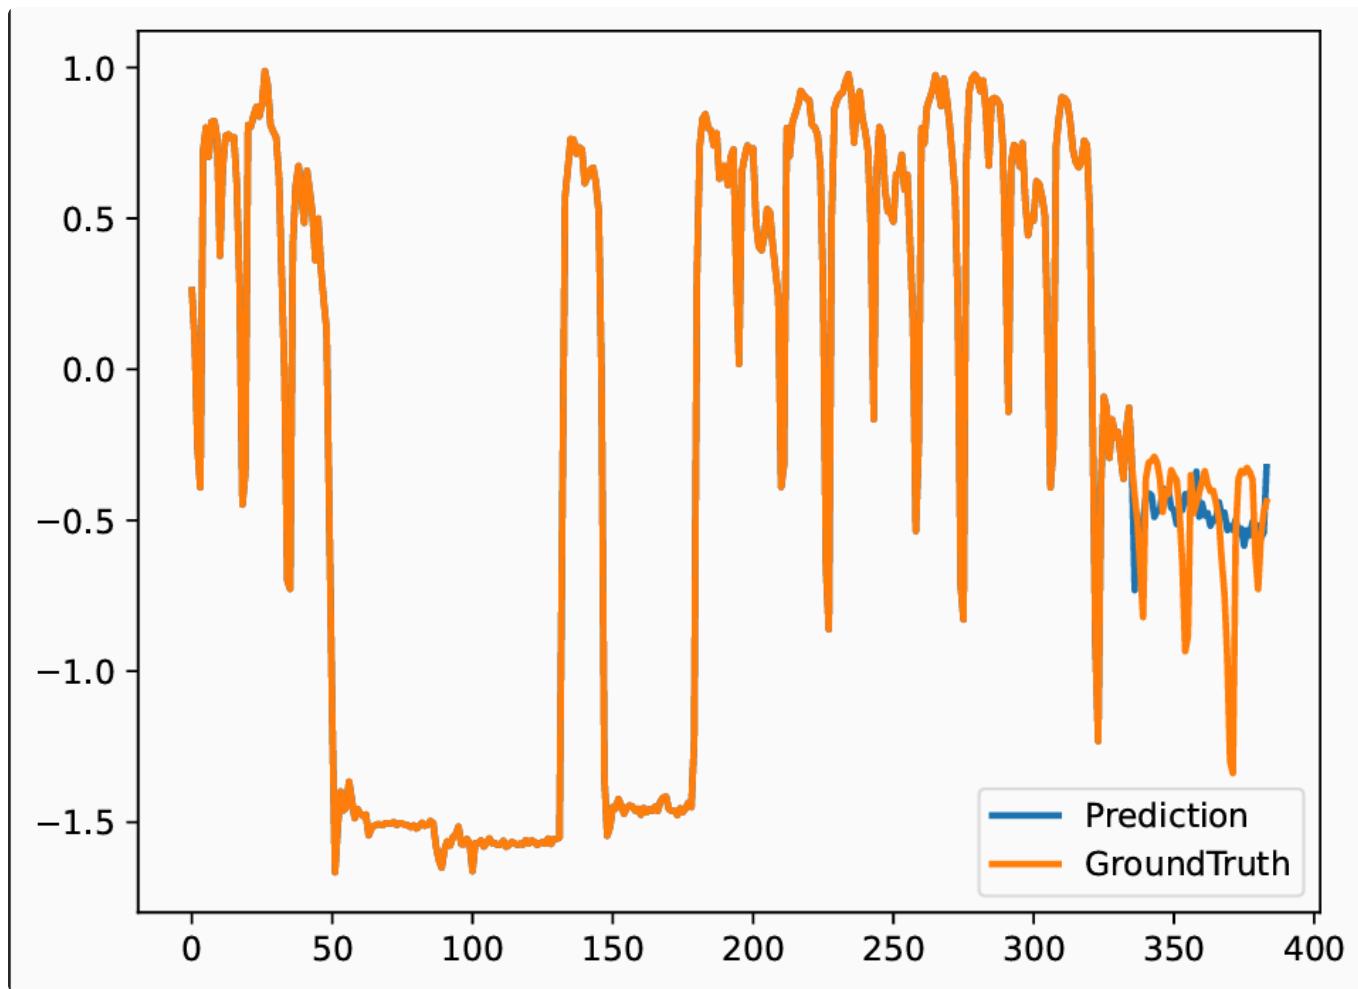
mse:0.41839835047721863, mae:0.5191811323165894, dtw:Not calculated

TSMixer



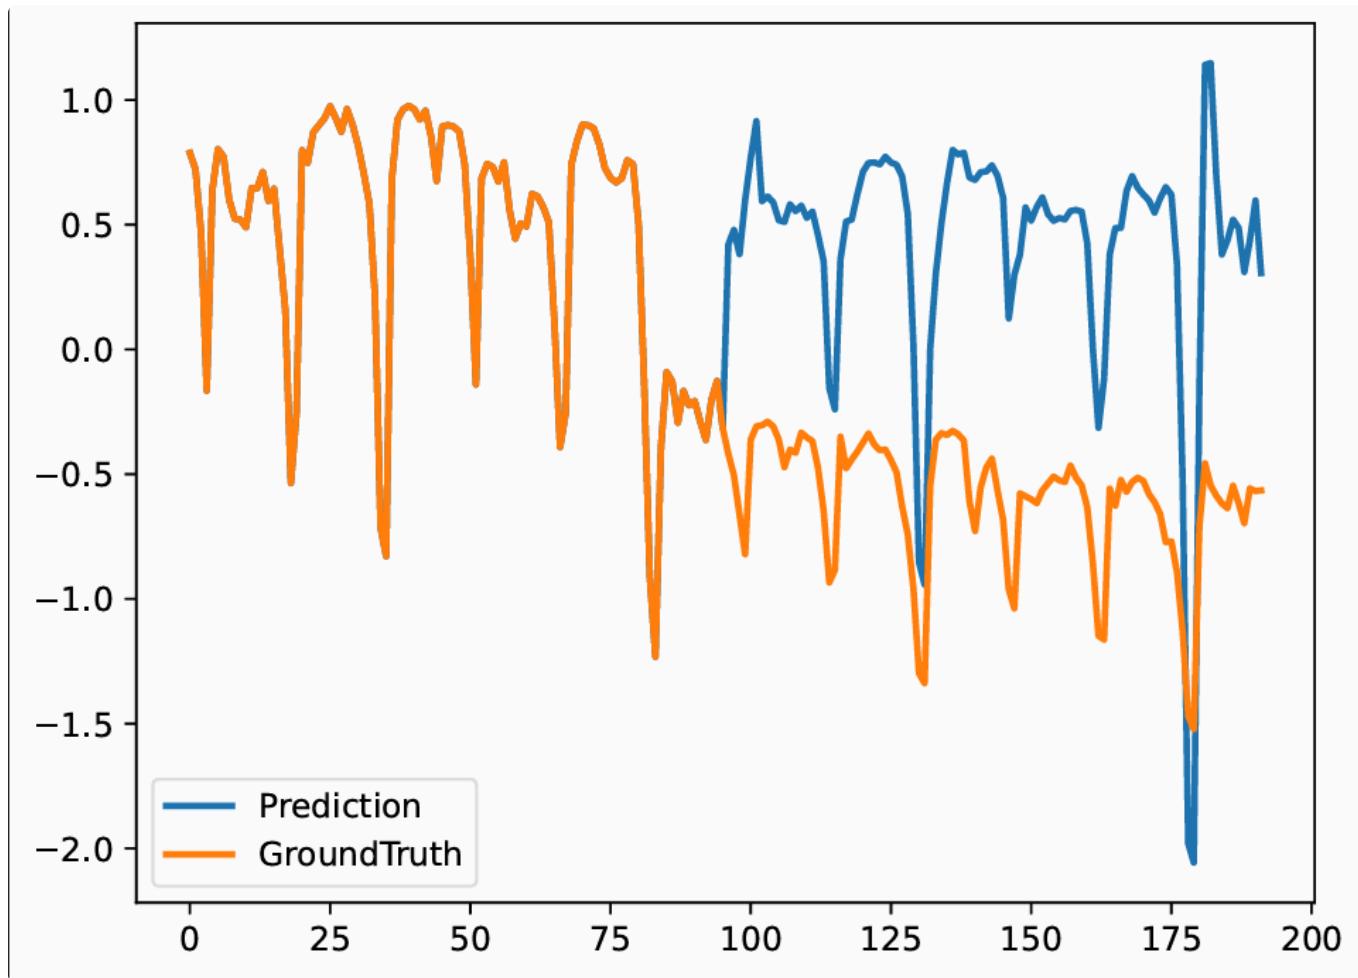
mse:0.6191823482513428, mae:0.645122766494751, dtw:Not calculated

Transformer



mse:0.3225320875644684, mae:0.3842540383338928, dtw:Not calculated

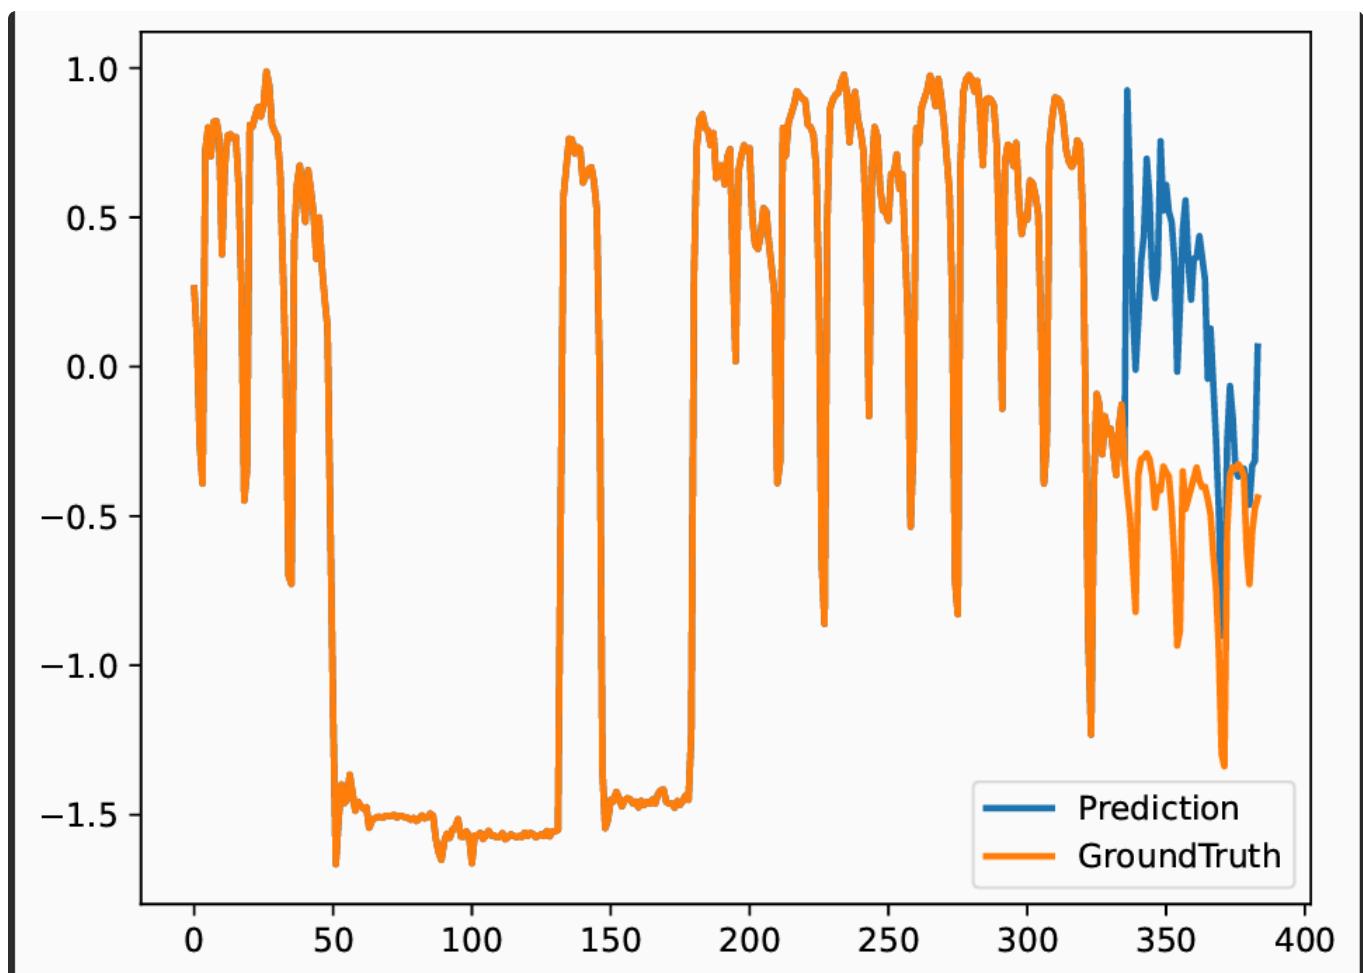
Mamba



mse:0.8967767953872681, mae:0.8106917142868042, dtw:Not calculated

24特征

Mabma



mse:0.3076019883155823

iTransformer

mse:0.32753437757492065